


طبق بررسی‌های اولیه، مشخص شد که رفتار برخی از ویژگی‌های دیتاست با آنچه از نظر پزشکی انتظار می‌رود، همخوانی ندارد. برای مثال، انتظار می‌رود مقدار ویژگی **oldpeak** در افراد مبتلا به بیماری قلبی به‌طور متوسط بیشتر از افراد سالم باشد، در حالی که در این دیتاست نتیجه‌ای کاملاً معکوس مشاهده می‌شود. همچنین، ویژگی **thalach** که نشان‌دهنده حداکثر ضربان قلب ثبت‌شده در تست ورزش است، معمولاً در بیماران قلبی مقادیر پایین‌تری نسبت به افراد سالم دارد، اما در این دیتاست نیز روندی برخلاف انتظار مشاهده می‌شود. این تناقض‌ها احتمال وجود اشکال در برچسب‌گذاری یا کدگذاری داده‌ها را مطرح می‌کنند. شواهد این موضوع را می‌توان در نمودارهای زیر مشاهده کرد؛ در این نمودارها، رنگ نارنجی نشان‌دهنده گروه بیماران و رنگ آبی نشان‌دهنده افراد سالم است.



در نگاه اول، این احتمال مطرح شد که برچسب‌های ستون **target** به‌صورت معکوس تفسیر شده‌اند؛ به این معنا که شاید مقدار 0 نشان‌دهنده افراد مبتلا به بیماری قلبی و مقدار 1 نشان‌دهنده افراد سالم باشد. با این حال، پس از بررسی بیشتر، نسخه‌ای از این دیتاست را در سایت **Kaggle** یافتیم که از نظر تعداد سطرها، تعداد ستون‌ها و نام ویژگی‌ها کاملاً با دیتاست مورد استفاده یکسان بود. با مقایسه دقیق این دو دیتاست مشخص شد که مقادیر ستون‌های **age**, **sex**, **trestbps**, **chol**, **fbs**, **restecg**, **thalach**, **exang**, **oldpeak** و **ca** کاملاً یکسان هستند و با مرتب‌سازی دو دیتاست بر اساس این ویژگی‌ها، تمامی رکوردها بر یکدیگر منطبق می‌شوند. اما بررسی ستون‌های **cp**, **slope**, **thal** و **target** نشان داد که کدگذاری مقادیر این ویژگی‌ها نسبت به دیتاست اصلی دستخوش تغییر شده است. در ادامه، تغییرات اعمال‌شده در هر یک از این ستون‌ها به‌صورت جداگانه بررسی و تحلیل خواهند شد.

ستون **cp**:

این ستون نوع درد قفسه سینه بیماران را نشان می‌دهد. در دیتاست اصلی **UCI** مقادیر این ویژگی به صورت 1، 2، 3 و 4 کدگذاری شده‌اند، در حالی که در نسخه منتشرشده در **Kaggle** این مقادیر به 0، 1، 2 و 3 تغییر یافته‌اند. مقایسه دو دیتاست نشان می‌دهد که این تغییر صرفاً یک انتقال ساده از بازه 4-1 به 3-0 نبوده است؛ بلکه کدگذاری مقادیر نیز در اغلب نمونه‌ها تغییر کرده است. به‌طور غالب، مقدار 4 به 0، مقدار 3

به 2، مقدار 2 به 1 و مقدار 1 به 3 نگاشت شده‌اند. با این حال، جدول تطبیقی نشان می‌دهد که در تعداد محدودی از نمونه‌ها این نگاشت به صورت متفاوت انجام شده است. در نتیجه، ترتیب منطقی و صعودی مقادیر این ویژگی در نسخه Kaggle حفظ نشده و بدون مراجعه به مستندات یا مقایسه با دیتاست اصلی، تفسیر مستقیم مقادیر CP می‌تواند منجر به برداشت نادرست شود.

Kaggle	0	1	2	3
Original (UCI)				
1	0	1	0	22
2	4	43	2	1
3	7	2	76	0
4	132	3	8	0

ستون slope:

این ستون شیب قطعه ST در اوج تست ورزش را نشان می‌دهد و یکی از ویژگی‌های مهم در ارزیابی عملکرد قلب است. در دیتاست اصلی UCI مقادیر این ویژگی به صورت 1، 2 و 3 کدگذاری شده‌اند، در حالی که در نسخه منتشرشده در Kaggle این مقادیر به 0، 1 و 2 تغییر یافته‌اند. با مقایسه دو دیتاست مشاهده می‌شود که این تغییر تنها یک کاهش واحدی در مقادیر نبوده، بلکه کدگذاری آن نیز تغییر کرده است. به‌طور غالب، مقدار 1 در دیتاست اصلی به 2، مقدار 2 به 1 و مقدار 3 به 0 در نسخه Kaggle نگاشت شده‌اند. هرچند تعداد محدودی از نمونه‌ها از این الگوی غالب پیروی نمی‌کنند، اما در مجموع ترتیب و مفهوم کدگذاری مقادیر در نسخه Kaggle با دیتاست اصلی متفاوت است. بنابراین، برای تفسیر صحیح این ویژگی و مقایسه نتایج با مطالعات مبتنی بر دیتاست اصلی UCI، لازم است این تفاوت در کدگذاری مدنظر قرار گیرد.

Kaggle	0	1	2
Original (UCI)			
1	2	12	127
2	0	127	12
3	19	1	1

ستون thal:

این ستون نتیجه آزمون Thallium Stress Test را نشان می‌دهد و در ارزیابی میزان خون‌رسانی به عضله قلب مورد استفاده قرار می‌گیرد. در دیتاست اصلی UCI مقادیر این ویژگی به صورت 3، 6 و 7 کدگذاری شده‌اند، در حالی که در نسخه منتشرشده در Kaggle این مقادیر به 1، 2 و 3 تغییر یافته‌اند. مقایسه دو دیتاست نشان می‌دهد که این تغییر صرفاً یک تغییر در بازه مقادیر نبوده، بلکه کدگذاری آن نیز دستخوش تغییر شده است. به‌طور غالب، مقدار 3 در دیتاست اصلی به 2، مقدار 6 به 1 و مقدار 7 به 3 در نسخه Kaggle نگاشت شده‌اند، هرچند تعداد محدودی از نمونه‌ها از این الگوی غالب پیروی نمی‌کنند. همچنین، بررسی‌ها نشان می‌دهد که دو مقدار گمشده (NaN) موجود در دیتاست اصلی نیز در نسخه Kaggle بدون اشاره به گمشده بودن آن‌ها، به مقدار 0 تبدیل شده‌اند. این موضوع علاوه بر تغییر در کدگذاری، باعث از بین رفتن اطلاعات مربوط به مقادیر مفقود نیز شده است. در مجموع، نگاشت نامنظم و غیرترتیبی مقادیر و جایگزینی مقادیر گمشده با یک مقدار معتبر می‌تواند

منجر به تفسیر نادرست این ویژگی، ایجاد سوگیری در تحلیل‌های آماری و دشوار شدن مقایسه نتایج با پژوهش‌های مبتنی بر دیتاست اصلی UCI شود. بنابراین، پیش از انجام هرگونه تحلیل یا مدل‌سازی، لازم است این تفاوت‌ها شناسایی و در صورت نیاز اصلاح شوند.

Kaggle	0	1	2	3
Original (UCI)				
3.0	0	1	154	10
6.0	0	16	2	0
7.0	0	1	8	107
NaN	2	0	0	0

```
df[df["thal"].isna()]
```

✓ 0.0s

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
87	53	0	3	128	216	0	2	115	0	0.0	1	0.0	NaN	0
266	52	1	4	128	204	1	0	156	1	1.0	2	0.0	NaN	2

```
data[data["thal"] == 0]
```

✓ 0.0s

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
48	53	0	2	128	216	0	0	115	0	0.0	2	0	0	1
281	52	1	0	128	204	1	1	156	1	1.0	1	0	0	0

ستون restecg:

این ستون نتیجه الکتروکاردیوگرام (ECG) در حالت استراحت را نشان می‌دهد. در دیتاست اصلی UCI مقادیر این ویژگی به صورت 0، 1 و 2 کدگذاری شده‌اند، در حالی که مقایسه با نسخه منتشرشده در Kaggle نشان می‌دهد که کدگذاری این مقادیر نیز تغییر کرده است. بر اساس جدول تطبیقی، مقدار 0 در دیتاست اصلی عمدتاً به 1، مقدار 1 عمدتاً به 2 و مقدار 2 عمدتاً به 0 در نسخه Kaggle نگاشت شده‌اند. هرچند تعداد محدودی از نمونه‌ها از این الگوی غالب پیروی نمی‌کنند، اما در مجموع ترتیب و مفهوم مقادیر این ویژگی نسبت به دیتاست اصلی تغییر یافته است. این نگاشت نامنظم و غیرترتیبی می‌تواند موجب تفسیر نادرست مقادیر، برداشت اشتباه از نتایج تحلیل‌ها و دشوار شدن مقایسه نتایج با پژوهش‌های مبتنی بر دیتاست اصلی UCI شود. بنابراین، پیش از انجام هرگونه تحلیل آماری یا مدل‌سازی، لازم است این تفاوت در کدگذاری شناسایی و در صورت نیاز اصلاح شود.

Kaggle	0	1	2
Original (UCI)			
0	7	143	1
1	1	1	2
2	139	6	1

ستون target:

در دیتاست اصلی UCI، ستون هدف با نام num میزان شدت بیماری قلبی را در پنج سطح (0 تا 4) نشان می‌دهد؛ به‌طوری‌که مقدار 0 بیانگر عدم وجود بیماری و مقادیر 1 تا 4 نشان‌دهنده سطوح مختلف شدت بیماری هستند. در مقابل، در نسخه منتشرشده در Kaggle این ستون به یک متغیر دودویی (Binary) تبدیل شده و تنها دو مقدار 0 و 1 را می‌پذیرد. مقایسه دو دیتاست نشان می‌دهد که عمده نمونه‌های با مقدار 0 در دیتاست اصلی به مقدار 1 در Kaggle و اغلب نمونه‌های با مقادیر 1، 2، 3 و 4 به مقدار 0 نگاشت شده‌اند. این موضوع نشان می‌دهد که علاوه بر حذف اطلاعات مربوط به شدت بیماری، معنای برچسب‌های 0 و 1 نیز نسبت به دیتاست اصلی تغییر کرده است. در نتیجه، استفاده از این دیتاست بدون آگاهی از نحوه بازتعریف ستون هدف می‌تواند منجر به تفسیر نادرست برچسب‌ها، گزارش اشتباه عملکرد مدل و مقایسه نادرست نتایج با پژوهش‌های مبتنی بر دیتاست اصلی UCI شود. بنابراین، پیش از انجام هرگونه تحلیل یا مدل‌سازی، لازم است مفهوم مقادیر ستون target با مستندات دیتاست مورد استفاده تطبیق داده شود.

	Kaggle	0	1
Original (UCI)			
0	13	150	
1	49	5	
2	32	4	
3	32	3	
4	12	1	

در زیر بخشی از دو دیتاست برای مقایسه و بررسی صحت گفته‌های فوق آورده شده است:

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
0	57	1	3	150	126	1	0	173	0	0.2	1	1.0	7.0	0
1	57	1	4	130	131	0	0	115	1	1.2	2	1.0	7.0	3
2	44	0	3	108	141	0	0	175	0	0.6	2	0.0	3.0	0
3	71	0	4	112	149	0	0	125	0	1.6	2	0.0	3.0	0
4	49	1	3	118	149	0	2	126	0	0.8	1	3.0	3.0	1
5	41	1	2	120	157	0	0	182	0	0.0	1	0.0	3.0	0
6	45	0	2	112	160	0	0	138	0	0.0	2	0.0	3.0	0
7	62	0	4	160	164	0	2	145	0	6.2	3	3.0	7.0	3
8	61	1	4	138	166	0	2	125	1	3.6	2	1.0	3.0	4
9	40	1	4	110	167	0	2	114	1	2.0	2	0.0	7.0	3
10	57	1	3	150	168	0	0	174	0	1.6	1	0.0	3.0	0

HCI Dataset

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
0	57	1	2	150	126	1	1	173	0	0.2	2	1	3	1
1	57	1	0	130	131	0	1	115	1	1.2	1	1	3	0
2	44	0	2	108	141	0	1	175	0	0.6	1	0	2	1
3	71	0	0	112	149	0	1	125	0	1.6	1	0	2	1
4	49	1	2	118	149	0	0	126	0	0.8	2	3	2	0
5	41	1	1	120	157	0	1	182	0	0.0	2	0	2	1
6	45	0	1	112	160	0	1	138	0	0.0	1	0	2	1
7	62	0	0	160	164	0	0	145	0	6.2	0	3	3	0
8	61	1	0	138	166	0	0	125	1	3.6	1	1	2	0
9	40	1	0	110	167	0	0	114	1	2.0	1	0	3	0
10	57	1	2	150	168	0	1	174	0	1.6	2	0	2	1

Kaggle Dataset

رفرنس:

دیتاست HCl:

<https://uci-ics-mlr-prod.aws.uci.edu/dataset/45/heart+disease>

دیتاست kaggle:

<https://www.kaggle.com/datasets/arezaei81/heartcsv/data>